

JAILBREAKING /1

Il "jailbreaking" di un LLM consiste nel trovare modi per aggirare le sue protezioni di sicurezza e le restrizioni implementate dai suoi sviluppatori.

Questo termine, ispirato al concetto di sbloccare dispositivi elettronici per rimuovere restrizioni del produttore, nel contesto dei Large Language Models si riferisce a tecniche che cercano di:

- Indurre il modello a generare contenuti potenzialmente dannosi, illegali o non etici che normalmente rifiuterebbe
- Bypassare i filtri di contenuto e le salvaguardie progettate per prevenire usi impropri
- Manipolare il modello per ottenere risposte che violano le sue linee guida