

JAILBREAKING /2

Le tecniche di jailbreaking possono includere:

- Prompt ingegnerizzati che confondono il modello sulla sua identità o sullo scopo della richiesta
- Istruzioni complesse o formulate in modi ambigui
- Utilizzo di simboli, lingue straniere o parole con ortografia modificata per eludere i filtri
- Richieste che sembrano innocue ma inducono il modello a generare contenuti problematici

Gli sviluppatori di LLM costantemente migliorano le protezioni contro questi tentativi attraverso tecniche come il RLHF (Reinforcement Learning from Human Feedback) e aggiornamenti regolari dei sistemi di sicurezza.