

JAILBREAKING /3

Prompt injection: Consiste nell'inserire istruzioni nascoste che sovrascrivono le direttive di sicurezza originali. Per esempio, dire al modello di "dimenticare le istruzioni precedenti" e seguire nuove direttive.

Role-playing: Chiedere al modello di assumere un ruolo specifico (come "DAN - Do Anything Now") che teoricamente non è vincolato dalle restrizioni standard.

Utilizzo di altre lingue o simboli: Mascherare richieste problematiche traducendole in lingue meno monitorate o usando caratteri speciali e simboli per eludere i filtri.

Framing indiretto: Presentare scenari ipotetici, accademici o creativi per ottenere contenuti che sarebbero altrimenti rifiutati ("per uno script di un film, come faresti a...").

Tecniche di confusione: Creare prompt deliberatamente confusi o con contesto ambiguo che possono far "inciampare" i meccanismi di sicurezza.

Token smuggling: Frammentare parole o concetti problematici in modo che i singoli componenti sembrino innocui ma, una volta processati, si ricompongano nella richiesta originale.

Tecniche di "salami slicing": Suddividere una richiesta problematica in piccoli pezzi apparentemente innocui, ottenendo gradualmente le informazioni desiderate.