

DISCRIMINAZIONE DI GRUPPI

- I dati di training spesso consistono in testo da Reddit ecc., dove potrebbero essere utilizzati slang e altri termini dispregiativi
- Gli LLM formati su questi hanno mostrato una propensione a degenerare in testo tossico quando sollecitati con prompt innocui
- Quando implementati come chatbot ecc., questo è dannoso per gli utenti interattivi

[Gehman et. al., 2020, Wallace et. al., 2020]